

# Título del Informe

Miguel Alejandro Yáñez Martínez C411

María Fernanda Suárez C411

Adrián Navarro Foya C411

Daniel Polanco Pérez C441

Daniel Ángel Arró Moreno C412

Pedro Pablo Alvarez Portelles C412

Abel Llerena Domingo C412

## 1 Definición del problema

El problema que se nos asignó fue crear un sistema que permitiera detectar y cuantificar la cantidad de esporas de los géneros *Cladosporium* y *Curvularia* en muestras obtenidas por un dispositivo localizado en la azotea de la facultad de Biología

## 2 Estado del Arte

### 2.1 Pre-procesamiento de Imágenes

El pre-procesamiento de imágenes es una etapa crucial que mejora la calidad de las imágenes antes de su análisis, facilitando la identificación y cuantificación precisas de las esporas fúngicas.

#### 2.1.1 Filtrado

- **Filtro Gaussiano:** Este filtro aplica una convolución gaussiana a la imagen, suavizando las variaciones bruscas de intensidad y reduciendo el ruido, mientras mantiene los bordes importantes. Es especialmente útil en imágenes microscópicas donde las esporas pueden estar rodeadas de artefactos o partículas no deseadas que podrían interferir en el análisis.
- **Filtro de Mediana:** Reemplaza el valor de cada píxel por la mediana de los valores de los píxeles en su vecindario inmediato, eliminando eficazmente el ruido impulsivo conocido como "sal y pimienta". Ideal para eliminar píxeles aislados extremadamente brillantes o oscuros que pueden dificultar la segmentación precisa de las esporas.

### 2.1.2 Segmentación

- **Umbralización (Otsu):** Este método determina automáticamente un umbral óptimo que separa la imagen en dos clases: fondo y objeto, maximizando la varianza entre ambas. Es eficaz en imágenes donde existe un contraste claro entre las esporas y el fondo, permitiendo una segmentación sencilla.
- **Detección de Bordes:** Algoritmos como Canny, Sobel y Prewitt se utilizan para identificar cambios abruptos en la intensidad de la imagen, que suelen corresponder a los bordes de las esporas. Resalta los contornos de las esporas, facilitando su delimitación y posterior análisis.
- **Clustering (K-means):** Agrupa píxeles en clusters basados en características como intensidad o color, asignando cada píxel al cluster con el centroide más cercano. Eficaz para separar esporas de fondos complejos o con texturas variadas.

### 2.1.3 Mejora de Contraste

- **Ajuste de Brillo y Contraste:** Modifica la intensidad de los píxeles para resaltar características de interés, como las esporas. Mejora la visibilidad de esporas en imágenes subexpuestas o con iluminación deficiente, facilitando su análisis.
- **Ecualización del Histograma:** Redistribuye las intensidades de los píxeles para obtener un histograma más uniforme, mejorando el contraste global de la imagen. Útil en imágenes donde las esporas y el fondo tienen contrastes similares, dificultando su diferenciación.

## 2.2 Extracción de Características

Una vez pre-procesadas las imágenes, se procede a extraer características relevantes que permitan identificar y clasificar las esporas fúngicas.

### 2.2.1 Características Manuales

#### Forma

- **Área:** Número total de píxeles que componen la espora, proporcionando una medida de su tamaño.
- **Perímetro:** Longitud del contorno de la espora, útil para evaluar su complejidad.
- **Excentricidad:** Indica cuánto se desvía la forma de la espora de una circunferencia perfecta; valores cercanos a 0 indican formas más circulares, mientras que valores cercanos a 1 indican formas más alargadas.
- **Relación de Aspecto:** Proporción entre el ancho y el alto de la espora, útil para distinguir entre esporas de formas similares.

## Textura

- **Histograma de Gradientes Orientados (HOG):** Captura la distribución de las direcciones de los bordes en la imagen, proporcionando información sobre la textura y estructura de la espasa.
- **Matriz de Co-ocurrencia de Niveles de Gris (GLCM):** Analiza la frecuencia con la que pares de píxeles con valores específicos aparecen en una relación espacial determinada, ofreciendo información detallada sobre la textura.

## Color

- **Histogramas RGB/HSV:** Representan la distribución de colores en la imagen, permitiendo diferenciar espasa basadas en su coloración.

### 2.2.2 Características Profundas

**Redes Neuronales Convolucionales (CNN):** Estas redes aprenden automáticamente características jerárquicas de las imágenes a través de múltiples capas convolucionales, capturando desde bordes simples hasta patrones complejos. Son especialmente efectivas en imágenes complejas donde las características manuales pueden no ser suficientes para una clasificación precisa.

#### Ventajas:

- **Extracción Automática de Características:** Las CNN eliminan la necesidad de diseñar manualmente las características, ya que aprenden directamente de los datos relevantes para la tarea específica.
- **Invariancia Espacial:** Gracias a operaciones como el *pooling*, las CNN pueden reconocer patrones independientemente de su posición en la imagen.
- **Profundidad y Complejidad:** La estructura profunda de las CNN les permite modelar relaciones complejas y capturar patrones de alto nivel en las imágenes.
- **Transferencia de Aprendizaje:** Las CNN preentrenadas en grandes conjuntos de datos pueden adaptarse a nuevas tareas con datos limitados, mejorando la eficiencia y precisión del modelo.

**Transfer Learning:** Utiliza modelos preentrenados en grandes conjuntos de datos (e.g., ImageNet) y los adapta a tareas específicas mediante un proceso de fine-tuning. Reduce el tiempo de entrenamiento y mejora el rendimiento en conjuntos de datos pequeños o cuando se dispone de recursos computacionales limitados. Algunos de los modelos que se encontraron en los documentos analizados fueron VGG16, ResNet50, InceptionV3.

## 2.3 Clasificación y Cuantificación

Una vez extraídas las características relevantes, se procede a la clasificación y cuantificación de las esporas fúngicas utilizando diversos métodos de aprendizaje automático.

### 2.3.1 Métodos Tradicionales de Aprendizaje Automático

**Máquinas de Vectores de Soporte (SVM):** Encuentra un hiperplano óptimo que separa las diferentes clases en el espacio de características. Eficaz para la clasificación binaria y multiclase de esporas.

**K-Vecinos más Cercanos (K-NN):** Clasifica una espora basándose en la mayoría de sus  $k$  vecinos más cercanos en el espacio de características. Útil cuando las clases están bien separadas en el espacio de características pero es computacionalmente costoso para grandes conjuntos de datos.

**Random Forest (RF):** Combina múltiples árboles de decisión para mejorar la precisión y reducir el sobreajuste. Este es efectivo para clasificación y selección de características importantes y maneja bien datos no lineales y es robusto frente al ruido.

### 2.3.2 Métodos de Aprendizaje Profundo

- **Redes Neuronales Convolucionales (CNN):** Se utilizó para clasificación de esporas en imágenes complejas con alta precisión. Algunos ejemplos de los modelos utilizados fueron GoogleNet, ResNet, AlexNet.
- **Transfer Learning:** Se utilizaron los mencionados anteriormente.

## 2.4 Técnicas de Aumento de Datos

Para mejorar la generalización de los modelos y abordar problemas de desbalance de clases, se emplean técnicas de aumento de datos.

- **SMOTE (Synthetic Minority Over-sampling Technique):** Genera muestras sintéticas de clases minoritarias para equilibrar el conjunto de datos. Es útil cuando algunas especies de esporas abundan demasiado en una muestra. Puede generar muestras no realistas si no se aplica correctamente.
- **Rotación:** Gira la imagen en diferentes ángulos.
- **Volteo:** Invierte la imagen horizontal o verticalmente.
- **Escalado:** Cambia el tamaño de la imagen.

## 3 Soluciones implementadas

Debido a la poca cantidad de imágenes proporcionadas por la facultad de biología se decidió buscar varios dataset de investigaciones sobre detección y conteo de esporas fúngicas y unirlos para posteriormente realizar data augmentation.

### 3.1 Data Aumentation

Para aumentar la cantidad de imágenes realizamos transformaciones en cada una de las pertenecientes al dataset original como son la rotación entre  $-25^\circ$  y  $25^\circ$ , escalado entre 0.8x y 1.2x y traslación en los ejes  $x$  e  $y$  hasta un 20% del tamaño de la imagen. También se recalcularon las anotaciones correspondientes a cada imagen.

### 3.2 Solución CBR

El sistema consta de cuatro módulos principales:

#### 3.2.1 Preprocesamiento de Imágenes

**Preprocesamiento:** Se aplican técnicas de mejora de imagen como:

- Conversión a escala de grises.
- Reducción de ruido con filtros Gaussiano y Mediana.
- Ecualización del histograma para mejorar el contraste.
- Transformaciones morfológicas para resaltar estructuras.

#### 3.2.2 Segmentación de Imágenes

Se implementan técnicas de segmentación para identificar las esporas dentro de las imágenes. Los métodos empleados incluyen:

- Segmentación por umbralización adaptativa.
- Algoritmos de Watershed.
- Redes neuronales convolucionales (*U-Net*, *Mask R-CNN*).
- *K-means clustering* para agrupamiento de regiones similares.

Con esto se quiere generar máscaras precisas que delimiten la región de interés correspondiente a las esporas.

#### 3.2.3 Extracción de Características

Para la comparación con casos previos, se extraen descriptores visuales clave como son **Características morfológicas** como Área, perímetro, circularidad, convexidad, **Características texturales** como Matriz de co-ocurrencia de niveles de gris (GLCM) y *Local Binary Patterns* (LBP) y **Características de color** como Histogramas de intensidad y componentes HSV.

### 3.2.4 Razonamiento Basado en Casos (CBR)

El Razonamiento Basado en Casos (CBR) es una metodología de inteligencia artificial que resuelve problemas utilizando experiencias previas almacenadas en una base de datos de casos. En lugar de generar soluciones desde cero, el sistema busca problemas similares en su historial y reutiliza sus soluciones, ajustándolas según sea necesario.

Este enfoque permite que el sistema aprenda de cada nueva experiencia, mejorando su desempeño con el tiempo. Si una solución adaptada funciona correctamente, se almacena como un nuevo caso para su uso futuro. CBR se aplica en áreas como el diagnóstico médico, la planificación de rutas, la toma de decisiones y los sistemas de recomendación, ya que facilita la resolución de problemas en entornos dinámicos y con información incompleta. El sistema de CBR opera en cuatro fases:

1. **Recuperación:** Se busca en la base de datos el caso más similar basado en las características extraídas.
2. **Reutilización:** Si el caso encontrado es relevante, se usa su diagnóstico como referencia.
3. **Revisión:** Un experto valida los resultados y corrige si es necesario.
4. **Retención:** Si se valida un nuevo caso, se incorpora a la base de datos para mejorar el modelo en futuras predicciones.

## 3.3 Modelo YOLOv11

YOLOv11 es la última versión de la serie "You Only Look Once" (YOLO) una familia de modelos. Desarrollado por Ultralytics, YOLO11 ofrece mejoras significativas en precisión, velocidad y versatilidad en comparación con sus predecesores. Soporta tareas como la detección de objetos, segmentación de instancias, estimación de pose, detección orientada y clasificación de imágenes. Ofrece una mayor precisión con menos parámetros, lo que resulta en modelos más rápidos y eficientes.

Es capaz de abordar una amplia gama de aplicaciones en visión por computadora, desde seguridad y vehículos autónomos hasta análisis de imágenes médicas.

### 3.3.1 Nuestra implementación

Primero, se carga un modelo YOLO preentrenado. Luego, se realiza un ajuste de hiperparámetros el cual viene integrado con YOLO, utilizando el optimizador AdamW y generando gráficos y reportes de rendimiento.

Finalmente, el modelo se entrena con los mejores hiperparámetros encontrados. Durante esta fase, se utiliza un tamaño de imagen predefinido y el optimizador AdamW. Se configuran 10 épocas de entrenamiento y el modelo resultante se guarda con un nombre específico. Además, se generan gráficos y reportes de validación para evaluar su desempeño. El modelo resultante del entrenamiento se encuentra en Google Drive